

# Первопорядковый логический вывод при решении задач распознавания с использованием результатов, полученных алгоритмически и нейросетевыми методами

Evgeny Cherkashin

Институт динамики систем и теории управления СО РАН,  
Иркутск, Россия  
[bychkov@icc.ru](mailto:bychkov@icc.ru)

2024 октября, Новосибирск



# Проблематика распознавания сценариев

1. Термин искусственный интеллект (ИИ) в настоящее время связывают с моделями, основанными на машинном обучении (МО):
  - ▶ нейронными сетями, включая этапы свертки,
  - ▶ генерирующими нейронными сетями,
  - ▶ моделями регрессии, таксономии, классификации на основе машинного обучения и т. п.
2. Известное ограничение применимости МО – невозможность интерпретации получаемых моделей в виде процедуры трансформации данных: нейронная сеть – это набор коэффициентов.
3. Другое ограничение МО – сложность построения моделей МО распознавания свойств (динамических систем), например, свойств процесса, представленного набором кадров видео. Необходимо уметь распознавать
  - ▶ набор допустимых состояний объектов, их классификация,
  - ▶ классы «недопустимых» и «целевых» состояний,
  - ▶ правила перехода объектов из состояния в состояние,
  - ▶ правила изменения свойств при выполнении перехода,
  - ▶ общий сценарий (модель) поведения объектов.

# Проблематика распознавания сценариев

1. Применение МО требует большой объем данных для обучения, тестирования, верификации.
2. Предлагаемый вариант модели решения – построение иерархической системы моделей распознавания на основе существующих моделей МО «общего назначения»:
  - ▶ нижние уровни – результаты распознавания алгоритмами и моделями МО,
  - ▶ средние уровни – анализ статических свойств сцен,
  - ▶ более высокие уровни – анализ (распознавание) динамических свойств.

Результат анализа – классификация сценария (модели) и идентификация параметров.

3. Структуры данных результата далее интерпретируются, например, трансформируются в новую модель.
4. Вкладываем ресурсы не в создание новой модели МО с непредсказуемыми свойствами, а в построение моделей рассуждения.

# Инструменты реализации

1. Алгоритмы распознавания (регулярные выражения, свертки).
2. Универсальные предобученные нейронные сети.
3. Хранилища разноформатных данных, накапливающие семантическую информацию об объектах.
4. Обеспечение доступа к внешним данным и знаниям.
5. Логическое программирование (ЛП): языки, реализации.
6. Методики представления моделей на языках ЛП:
  - ▶ моделирование сценариев,
  - ▶ процедур идентификации структур и параметров,
  - ▶ трансформации получаемых структур.

## Экспериментальный инструментарий


- ❑ Предобученная НС изображений (Segment Anything, 2024).
- ❑ Хранение данных в распределенных графах знаний. Linked Open Data (LOD), SPARQL.
- ❑ Язык логического ООП (ЛООП) Logtalk - макропакет над разными реализациями ISO-Prolog.
- ❑ Методики применения ЛООП при проектировании моделей распознавания и трансформации.

Выбран, т.к. имеет следующие свойства.

- ❑ наследует широко известный синтаксис и среду исполнения Prolog;
- ❑ реализован как макропакет, потери производительности составляют около 1.5-10%;
- ❑ имеет гибкую семантику: преобразования и ограничения определяются в рамках одного и того же синтаксиса;
- ❑ реализует объектно-ориентированное структурирование знаний (правил), инкапсуляцию и замену;
- ❑ из преобразований можно строить композиции;
- ❑ механизм включения ограничений перехватом сообщений объекта к объекту (событий);
- ❑ есть варианты для различных реализаций ISO Prolog.



# Интерпретация как трансформация. Model-Driven Architecture



MDA Model-Driven Architecture

CIM Computationally Independent Model

CM Model of Computations

PIM Platform Independent Model

PM Platform Model

PSM Platform-Specific Model

CODE Генерируемый исходный код

DATA Начальное состояние баз данных



Основная цель НИРОКР разработать технологии MDA, где модели CIM, PIM представлены в языках SysML, UML, BPMN, CMMN с использованием Семантического веба:

1. CIM представляется в UML, SysML, BPMN, CMMN, или как результат анализа текстов программ,
2. PIM, PSM представляется в UML и в RDF с использованием стандартных онтологий,
3. трансформации реализуются в языке Logtalk,
4. сервера LOD запрашиваются на предмет дополнительной информации,
5. порождение документов и интерфейсов пользователя, размеченных по требованиям LOD.

# Технологии семантического веба – элемент моделей трансформации

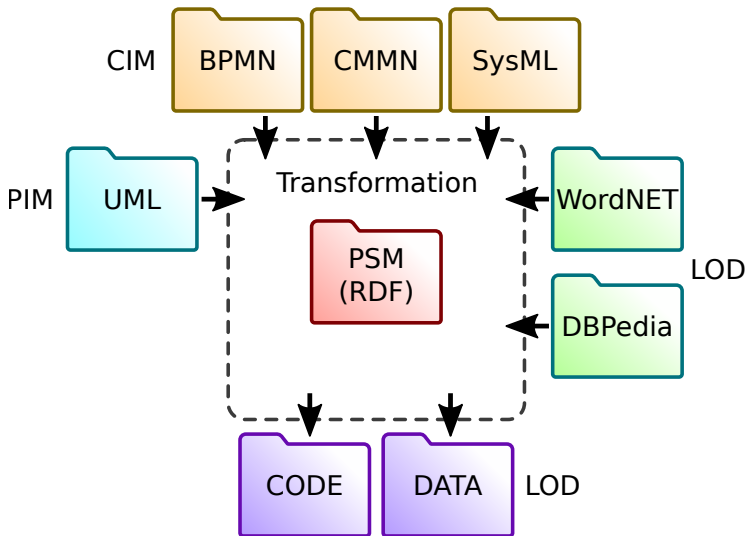
- ❑ Использование результатов исследований, формализации и стандартизации предметных областей
- ❑ Граф знаний задается множеством троек
- ❑ Онтологии описываются формально (`rdfs:domain`, `rdfs:range`);
- ❑ Поддержаны в большинстве систем программирования библиотеками, механизмами логического вывода, SPARQL
- ❑ Существует способ глобальной идентификации объектов в RDF: в разных программах можно идентифицировать один и тот же объект
- ❑ SWI-Prolog поддерживает механизмы прямых запросов к графу и интерпретацию некоторых отношений (`rdfs:label`, `dc:title`)
- ❑ Простая поддержка разделения доступа к информации (`rdfs:seeAlso`)
- ❑ Семантический веб и LOD – основа интеграции приложений

# Связанные открытые данные, LOD

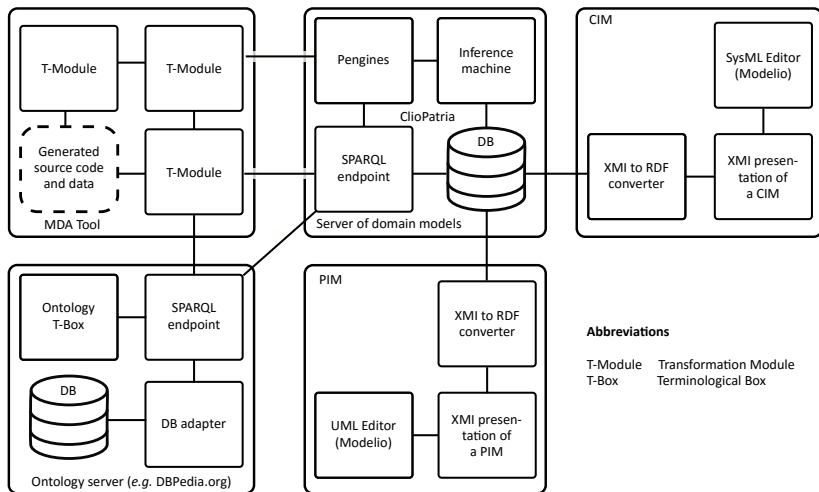
1. Информация публикуется в Интернете с лицензией открытого доступа
2. Он представлен в машиночитаемой форме, например, таблица Excel вместо растрового изображения
3. открытый формат, используемый, например, CSV вместо Excel
4. Формат основан на рекомендуемых стандартах W3C, что позволяет ссылаться на RDF и SPARQL
5. Опубликованные данные относятся к объектам, образующим контекст

Таким образом, приложения публикуют данные как отношения объектов (сущностей)

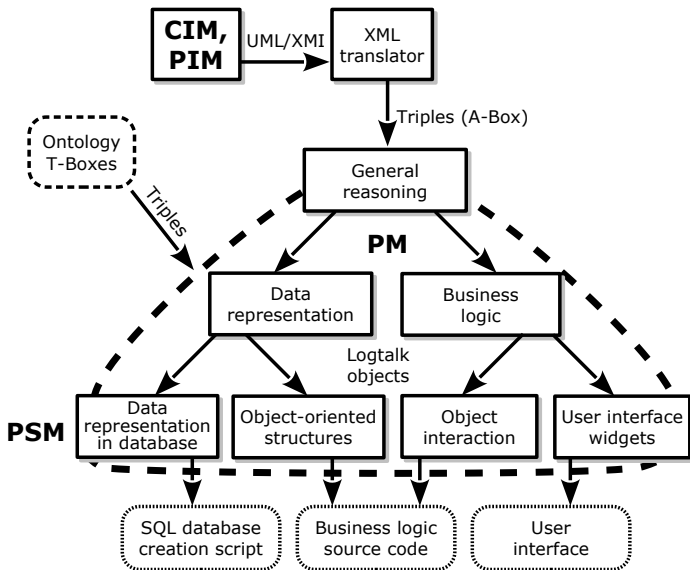
# Model Driven Architecture and Linked Open Data



# Инфраструктура MDA



# Процесс трансформации



# Сценарий синтеза PSM

```
:- object(direct(_Package,_LocalProf,_CodeProf)).
:- public([tr/4,tr/3]).
% . . . . .
tr(class, Class, ClassID):- ::package(Package),
    query(Package)::class(Name, ClassID),
    create_object(Class, % . . . . .
    create_object(Attributes, % . . . . .
    create_object(Methods, % . . . . .
    Class::name(Name),
    % Generate attributes of the class,
    % organizing them in a local database.
    % ...methods...
    Class::attributes(Attributes),
    Class::methods(Methods).

tr(attribute, Attribute, ClassID, AttributeID):-
    ::package(Package),
    query(Package)::attribute(Name,ClassID,AttrID),
    create_object(Attribute, % . . . . .
    Attribute::name(Name).

tr(method, Method, ClassID, MethodID):-
    ::package(Package),
    query(Package)::method(Name,ClassID,MethodID),
    create_object(Method, % . . . . .
    Method::name(Name).
:- end_object.
```

*% Transformation driver object*  
*% Public interface of a class synthesis scenario*

*% Synthesize a class*  
*% Query package structure in RMI*  
*% Create a «Class» object*  
*% Create «Attributes» object*  
*% ...«Methods».*  
*% Name the class.*

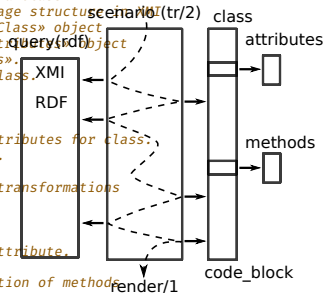
*% Set the attributes for class.*  
*% ...methods.*

*% Attribute transformations*

*% Name the attribute.*

*% Transformation of methods*

*% Name of the method*




# Обрамление модели PSM

```
:- object(query(_XMI)).
:- protected(xmi/1).
:- public([class/2, attribute/3, method/3]).
xmi(XMI) :- parameter(1, XMI).
class(Name, ID):-                                     % Recognition of Class
    ::xmi(XMI),
    XMI::rdf(ID,rdf:type,uml:'Class'),
    XMI::rdf(ID,rdfs:label, literal(Name)).
attribute(Name, ClassID, ID):-                       % ...attribute...
    ::xmi(XMI),
    XMI::rdf(ClassID, xmi:ownedAttribute, ID),
    XMI::rdf(ID, rdfs:label, literal(Name)).
method(Name, ClassID, ID):-                          % ...method...
    ::xmi(XMI),
    XMI::rdf(ClassID, xmi:ownedOperation, ID),
    XMI::rdf(ID, rdfs:label, literal(Name)).
% . . . . .
:- end_object.
```



# Блок кода. Идея – llvmlite\*


```
- object(code_block, specializes(root)).
% Public interface of the object
- public([append/1, prepend/1, clear/0,
         render/1, render_to/1, remove/1,
         item/1, items/1]).
% Code block items
- dynamic([item_/1]).
- private([item_/1]).
% Methods specialized during inheritance
- protected([renderitem/2, render_to/2]).
% . . . . .
% Delegate rendering to object itself
renderitem(Object, String):-
    current_object(Object, !,
        Object::render(String).
% Convert a literal to its string
% representation
renderitem(literal(Item), String):-!,
    atom_string(Item, String).
% Just print the item (debugging).
renderitem(Item, String):-
    root::iswritef(String, '%q', [Item]).
- end_object.
```



\*) <https://github.com/numba/llvmlite>


# PSM-модель класса Python – специализация блока кода

```
:- object(class, specializes(code_block),
    imports([named])). % Category of named entities
:- public([classlist/1, methods/1, attributes/1]).
% . . . . .
renderitem(Item, Result):- % proceed with default
    ^^renderitem(Item, Result). % rendering
render(Result):- % Source generator
    ^^render(Name), % implemented in a category
    ( ::item(classlist(List)) ->
        % . . . . .
        [Name]) ),
    ( ::item(attributes(Attributes))->
        % . . . . .
        [DefAttrList]),
    Attributes::items(InstanceAttrs),
    findall(S, ( % initialize attributes
        % . . . . .
        ), AttrAssigns),
    root::unindent,
    AttrList=[ConstructorDef|AttrAssigns];
    % . . . . .
    AttrList=[ConstructorDef, Pass] ),
    ( ::item(methods(Methods))-> % If any ...
        Methods::render(MethodList);
        MethodList=[] ),
    lists::append(AttrList,MethodList,StringList),
    root::unindent. Result=[Signature|StringList].
```

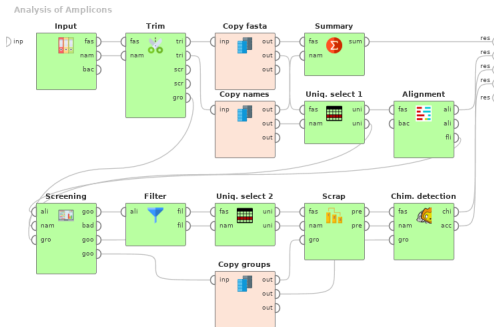


# Доступ к данным LOD

```
:- category(sparql).  
:- public(query/2).  
query(Pattern, Parameters, Row):-  
    prepare(Pattern, Parameters, Query),  
    server(Host, Port, Path),  
    sparql_query(Query, Row,  
        [host(Host), port(Port), path(Path)]).  
:- protected(server/3). % must be implemented  
                                % by a subclass.  
:- protected(prepare/3). % prepares a query  
% . . . . . % string.  
:- end_category.  
  
:- object(dbpedia, extends(sparql)).  
:- protected(server/3).  
server('dbpedia.org', 80, '/sparql').  
:- public(entity_name/2).  
entity_name(Entity, Language, Name):-  
    query('select ?name where { '  
        ' %w rdfs:label ?name. '  
        'FILTER langMatches( lang(?label), '  
        ' "%w" )}'', [Entity, Language],  
        row(Name)).  
:- end_object.  
  
% ?- dbpedia::entity_name(dbr:'Passport', 'ru', Name).
```



# Приложение: Диаграммы потока исполнения в NGS



Термин	Расшифровка
NGS	New Generation Sequencing
Amplicon	часть ДНК, РНК, скопированная много раз
Mothur	прикладной пакет для NGS
Rapidminer	визуальный инструмент для моделирования процессов Data Mining и их исполнения

Зеленые блоки — это модули Mothur. Остальные – модули Rapidminer.

# Модуль Rapidminer

```
vector<string> AlignCommand::setParameters(){ // PART OF MODULE SOURCE
```

```
try {
```

```
    CommandParameter ptemplate("reference", "InputTypes", "", "", "none", "none", "none", "", false, true, true); p
```

```
    CommandParameter pcandidate("fasta", "InputTypes", "", "", "none", "none", "none", "fasta-alignreport-accnos
```

```
    CommandParameter psearch("search", "Multiple", "kmer-blast-suffix", "kmer", "", "", "", "", false, false, true)
```

```
    CommandParameter pksize("ksize", "Number", "", "8", "", "", "", "", false, false); parameters.push_back(pksize)
```

```
    CommandParameter pmatch("match", "Number", "", "1.0", "", "", "", "", false, false); parameters.push_back(pmat
```

```
// . . . . .
```

```
package com.rapidminer.ngs.operator; // GENERATED JAVA MODULE
```

```
// imports
```

```
class MothurChimeraCcodeOperator extends MothurGeneratedOperator {
```

```
    private InputPort fastaInPort = getInputPorts().createPort("fasta");
```

```
    private InputPort referenceInPort = getInputPorts().createPort("reference");
```

```
    private OutputPort chimeraOutPort = getOutputPorts().createPort("chimera");
```

```
    private OutputPort mapinfoOutPort = getOutputPorts().createPort("mapinfo");
```

```
    private OutputPort accnosOutPort = getOutputPorts().createPort("accnos");
```

```
    public MothurChimeraCcodeOperator (OperatorDescription description) {
```

```
        super(description);
```

```
    }
```

```
    @Override
```

```
    public void doWork() throws OperatorException {
```

```
        super();
```

```
        // . . . . .
```

```
    }
```

```
    @Override
```

```
    public List<ParameterType> getParameterTypes() {
```

```
        super();
```

```
        // . . . . .
```

```
    }
```

```
    @Override
```

```
    public String getOutputPattern(String type) {
```

```
        if (type=="chimera") return "[filename],[tag],ccode.chimeras-[filename],ccode.chimeras";
```

```
        if (type=="mapinfo") return "[filename],mapinfo";
```

```
        if (type=="accnos") return "[filename],[tag],ccode.accnos-[filename],ccode.accnos";
```

```
        return super.getOutputPattern(type);
```

```
    }
```

```
}
```

# Исходный граф RDF (TTL) и его обрамляющий объект

```
@prefix xml: <http://www.w3.org/.../namespace> .
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .
ngsp:spec a ngsp:Specification ;
    ngsp:module mothur:NoCommand,
        mothur:align-check,
        mothur:align-seqs,
# . . . . .
    mothur:align-check a ngsp:Module ;
        ngsp:outputPattern [ a cnt:Chars ;
            ngsp:parameterName "type" ;
            ngsp:pattern [ ngsp:patternString
                "[filename],align.check" ;
                dc:identifier "aligncheck" ] ;
            cnt:chars # . . . . .
# . . . . .
    mothur:align-check-idir-parameter
        a ngsp:Parameter ;
        ngsp:important false ;
        ngsp:multipleSelectionAllowed false ;
        ngsp:optionsDefault "" ;
        ngsp:required false ;
        ngsp:type mothur:String ;
        dc:title "inputdir" .

    mothur:align-check-map-parameter a ngsp:Parameter ;
        ngsp:important true ;
        ngsp:multipleSelectionAllowed false ;
        ngsp:optionsDefault "" ;
        ngsp:required true ;
        ngsp:type mothur:InputTypes ;
        dc:title "map" .

    mothur:align-check-name-parameter a ngsp:Parameter ;
        ngsp:chooseOnlyOneGroup "namecount" ;
        ngsp:important false ;
```

```
:- object(queryparam(_RDF,_Parameter),
    extends(ngsquerybase)).

:- public(type/1).
type(Type) :-
    ::attr(type, Type).
:- public(name/1).
name(Name) :- ::attr(dc:title, literal(Name)).
:- public(options/1).
options(Value):- ::attr(options, Value).
:- public(options_default/1).
options_default(Value):-
    ::attr(optionsDefault, Value).
% . . . . .
:- public(multiple_selection_allowed/0).
multiple_selection_allowed:-
    ::bool_attr(multipleSelectionAllowed).
:- public(required/0).
required:-
    ::bool_attr(required).
:- public(important/0).
important:-
    ::bool_attr(important).
:- protected(attr/2).
attr(NS:Name, Value):-
    ::ngs(RDF),
    ::second(Parameter),
    rdf_db::rdf_global_object(Value, V),
    RDF::rdf(Parameter, NS:Name, V).
attr(Name, Value):-
    \+ Name=_,!,
    ::ngs(RDF),
    ::second(Parameter),
    rdf_db::rdf_global_id(Value, V),
    RDF::rdf(Parameter, ngsp:Name, V).
```

Interesting positive impressions obtained:

- ❑ Logtalk and RDF are flexible, sufficiently universal and convenient implementation infrastructures for MDA;
- ❑ The best implementation means is Prolog predicate wrapping and Logtalk object encapsulation of rules;
- ❑ Not all Logtalk properties are investigated: there might be more sophisticated programming techniques developed, e.g., on the base of message watchers.

Technical problems making the approach somewhat problematic:

- ❑ Very simple tasks take too much efforts, e.g., text processing: convert an identifier into the CamelCase;
- ❑ It takes too long to surf Internet in order to find a vocabulary for a domain, but it is more productive than development;
- ❑ Prolog is not a popular language in MDA, neither Logtalk.

# Document authoring and storage

In most cases documents are created as a result of

- ❑ creative activity of a person with a text processors (authoring);
- ❑ printing a digital copy or a data record in a database;
- ❑ aggregation operation over database records (report).

Then it is stored either as a physical paper and/or a digital document (PDF, DOCX, HTML).


Since 2000-th, Semantic Web and Linked Open Data (LOD) is being developed, allowing

- ❑ structural storage of data within published documents;
- ❑ processing stored data computationally;
- ❑ integration of data structures and data objects globally.


The aim of this research is to develop technologies, software and services allowing construction of digital archives supporting document data inclusion and inference from existing documents.



# Structure of a document



# Open Annotation (oa)




# Representation

```
<html lang="ru" xmlns=http://www.w3.org/1999/xhtml
xmlns:taa=http://irnok.net/engine/rdfa-manipulation
xml:lang="ru" metal:define-macro="page">
<head> . . . . </head>
<body prefix="rdf: http://www.w3.org/1999/...-ns# foaf: http://xmlns.com/foaf/...
imei: imei.html# course: https://irnok.net/college/plan/01..16-...\
%D0%BA_PB-SM.plm.xml.xlsx-....2.3.1.html#" resource="#post"
typeof="schema:CreativeWork sioc:Post prov:Entity">
<!-- The application control panel -->

<main lang="ru" resource="#annotation" typeof="oa:Annotation" id="main-doc-cnt">
<div property="oa:hasTarget" resource="#course-work-prog"></div>
<article property="oa:hasBody" typeof="foaf:Document curr:WorkingProgram"
resource="#course-work-program" id="main-document">

  <div taa:content="imei:title-page"></div>
  <div taa:content="imei:neg-UMK"></div>
  <section id="TOC" class="break-after"> <h2>Table of Contents</h2>
    <div id="tableOfContents"></div>
  </section>
  <section id="course-description" resource="#description"
    property="schema:hasPart" typeof="schema:CreativeWork">
    <div property="schema:hasPart" resource="#purpose"
      typeof="dc:Text cnt:ContentAsText" >
      <div property="cnt:chars" datatype="xsd:string">
        <h2 property="dc:title" datatype="xsd:string">
          Aims and objectives of the discipline (module)</h2>
        <p>The aim of teaching the discipline ...</p>
      </div>
    </div>
  </div>
```

# Architecture



# Generated list of title page preambles



**МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ  
ФЕДЕРАЦИИ**  
федеральное государственное бюджетное образовательное учреждение  
высшего образования  
**«ИРКУТСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»**  
**ФГБОУ ВО «ИГУ»**  
Институт математики экономики и информатики

**Кафедра информационных технологий**



**МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ  
ФЕДЕРАЦИИ**  
федеральное государственное бюджетное образовательное учреждение  
высшего образования  
**«ИРКУТСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»**  
**ФГБОУ ВО «ИГУ»**  
Институт математики экономики и информатики

**Кафедра алгебраических и информационных систем**

УТВЕРЖДАЮ

## Учебный план специальности 01.03.02 Прикладная математика и информатика

### 1. Общие сведения учебного плана

#### Сведения по Учебному плану

Профиль подготовки: Математическое и компьютерное моделирование в технике и экономике, методы принятия решений

#### Сведения о кафедре, разработавшей Учебный план

Кафедра: Математического анализа и дифференциальных уравнений,  
Факультет: ИМЭИ.

#### Сведения о специальности

Квалификация: Бакалавр

Форма обучения: очная

Программа подготовки: прикладн. бакалавриат

#### Руководители

Проректор по учебной работе: Не распознан

Начальник УМУ: А.И. Вокин

Директор: М.В. Фалалеев

### 2. Список компетенций

Дисциплина: Б1.В.ДВ.3.1. Технологии программирования

- способность приобретать новые научные и профессиональные знания, используя современные образовательные и информационные технологии (ОПК-2)
- способность критически переосмысливать накопленный опыт, изменять при необходимости вид и характер своей профессиональной деятельности (ПК-3)
- способность к разработке и применению алгоритмических и программных решений в области системного и прикладного программного обеспечения (ПК-7)

### 3. Список курсов специальности

- Б1.Б.3 «Философия»

# Imported time distribution for lecture, seminary, ...

загрузке,

- методиками экстремального и *agile*-программирования.

## 4. Объем дисциплины (модуля) и виды учебной работы (разделяется по формам обучения)

Вид учебной работы	Всего часов / зачетных единиц	Семестры	
		3	4
Аудиторные занятия (всего)	108	33	75
в том числе:			
Лекции	36		36
Практические занятия (ПЗ)			
Семинары (С)			
Лабораторные работы (ЛР)	66	30	36
КСР	6	3	3
Самостоятельная работа (всего)	45	30	6

# Complete document



МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ  
ФЕДЕРАЦИИ  
федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«ИРКУТСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»  
ФГБОУ ВО «ИГУ»  
Институт математики экономики и информатики

Кафедра информационных технологий

УТВЕРЖДАЮ

Директор ИМЭИ

" " 20 г.

Рабочая программа дисциплины (модуля)  
Б1.В.ДВ.3.1. Технологии программирования

Направление подготовки:	10.03.01 (090900) Информационная безопасность
Направленность (профиль)	- общий
Квалификация (степень) выпускника	- бакалавр
Форма обучения	- очная

Иркутск 2016 г.

Согласовано с УМК факультета (института)

Рекомендовано кафедрой:

Протокол № от " " 20 г.

Протокол № от " " 20 г.

Председатель  
(подпись)

Зав. кафедрой  
(Ф.И.О.)

## Содержание

1. Цели и задачи дисциплины (модуля)
2. Место дисциплины в структуре ОПОП
3. Требования к результатам освоения дисциплины (модуля)
4. Объем дисциплины (модуля) и виды учебной работы (разделяется по формам обучения)
5. Содержание дисциплины (модуля)
6. Перечень семинарских, практических занятий и лабораторных работ
7. Примерная тематика курсовых работ (проектов)
8. Учебно-методическое и информационное обеспечение дисциплины (модуля)
9. Материально-техническое обеспечение дисциплины (модуля)
10. Образовательные технологии
11. Оценочные средства (ОС)

## 1. Цели и задачи дисциплины (модуля)

Цель преподавания дисциплины «Технологии программирования» является освоение студентами практических навыков в области разработки программного обеспечения на основе современных подходов к проектированию сложных, гетерогенных, распределенных информационных систем. Развитие навыков системного мышления, необходимого для



# Used ontologies

- ❑ Friend-of-a-friend (foaf) - agent information: individuals, legal entities, program agents.
- ❑ Provenance (prov) - references between documents.
- ❑ Dublin Core (dc) - edited annotation mark up.
- ❑ DBpedia resource (dbr) – references to instant objects and classes.
- ❑ Schema.org (schema) - Google, Yandex, Yahoo, etc. searchable objects, structural elements.
- ❑ The Bibliographic Ontology (bibo) - literature reference mark up.

# Conclusion

A tools (components) for digital archive implementation, which allows to device information systems and document processing services with the following features:

- ❑ load LOD marked up document, extract, store in a graph and index RDF data;
- ❑ retrieve RDF data as triples or as a result of full-text search query;
- ❑ combine existing LOD data and its content in new documents dynamically with browser based context inference machine;
- ❑ use server-site inference machine (Prolog) to process RDF data upon request from browser' s part of the system;
- ❑ convert created RDFa marked up HTML5 documents into Excel and Word formats.

## Applications

- ❑ Document authoring automation;
- ❑ Context-depended editing;
- ❑ Self-organizing global document flows;
- ❑ Documents as data sources for information systems.

## Software Platform for Rule-Based Spreadsheet Data Extraction and Transformation

Alexey Shigarov, Vasiliy Khristyuk, et al

`shigarov@icc.ru`

## □ About arbitrary spreadsheet tables

- ▶ A large volume of valuable data for science and business applications
- ▶ A big variety of layout, style, and content features
- ▶ Human-centeredness (incorrect structure and messy content)
- ▶ No explicit semantics for interpretation by computers

## □ Challenges

- ▶ How to extract tables from worksheets
- ▶ How to recognize and correct cell structure anomalies
- ▶ How to recover semantics needed for the automatic interpretation
- ▶ How to conceptualize extracted data by using external vocabularies

Table understanding includes the following tasks


1. Extraction — detecting a table and recognizing the physical structure of its cells
2. Role analysis — extracting functional data items from cell content
3. Structural analysis — recovering internal relationships between extracted functional data items
4. Interpretation — linking extracted functional data items with external vocabularies (general-purpose or domain-specific ontologies)

# Contribution

TabbyXL is a software platform aiming at the development and execution of rule-based programs for spreadsheet data extraction and transformation from arbitrary (a) to relational tables (b)

## Novelty

- Table object model assigning roles to data items, not cell
- CRL, domain-specific language to express user-defined rules for table analysis and interpretation
- CRL-to-Java translator to synthesize executable programs for spreadsheet data transformation



# Table Object Model

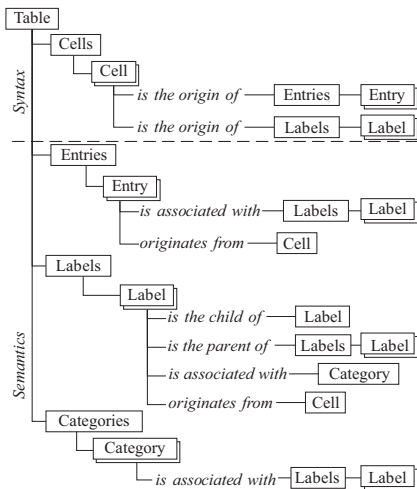
## Physical Layer

Cells characterized by layout, style, and content features

## Logical Layer

Functional data items and their relationships:

- ❑ entries (values)
- ❑ labels (keys)
- ❑ categories (concepts)
- ❑ entry-label pairs
- ❑ label-label pairs
- ❑ label-category pairs



# CRL Grammar

```
rule      = 'rule' <a Java integer literal> 'when' condition
           'then' action 'end' <EOL> {rule} <EOF>
condition = query identifier [':' constraint {',' constraint}
           [',' assignment {',' assignment}]] <EOL> {condition}
constraint = <a Java boolean expr>
assignment = identifier ':' <a valid Java expr>
query      = 'cell' | 'entry' | 'label' | 'category' | 'no cells' |
           'no entries' | 'no labels' | 'no categories'
action     = merge | split | set text | set indent | set mark |
           new entry | new label | add label | set parent |
           set category | group <EOL> {action}
merge      = 'merge' identifier 'with' identifier
split      = 'split' identifier
set text   = 'set text' <a Java string expr> 'to' identifier
set indent = 'set indent' <a Java integer expr> 'to' identifier
set mark   = 'set mark' <a Java string expr> 'to' identifier
new entry  = 'new entry' identifier ['as' <a Java string expr>]
new label  = 'new label' identifier ['as' <a Java string expr>]
add label  = 'add label' identifier | (<a Java string expr>
           'of' identifier | <a Java string expr>
           'to' identifier
set parent = 'set parent' identifier 'to' identifier
set category = 'set category' identifier | <a Java string expr>
           'to' identifier
group      = 'group' identifier 'with' identifier
identifier = <a Java identifier>
```



# Cell Cleansing

The actions correct an inaccurate layout and content of a hand-coded table

- ❑ **<merge>** combines two adjacent cells when they share one border
- ❑ **<split>** divides a merged cell that spans  $n$ -tiles (row-column intersections) into  $n$ -cells
- ❑ **<set text>** modifies a textual content of a cell
- ❑ **<set indent>** modifies a text indentation of a cell

## Example

```
when
  cell corner: cl == 1, rt == 1, blank
  cell c: cl > corner.cr, rt > corner.rb
then
  split c
```

# Role Analysis

The actions recover entries and labels as functional data items presented in a table

- ❑ **<set mark>** annotates a cell with a user-defined tag that can be used in subsequent table analysis
- ❑ **<new entry>** (**<new label>**) creates an entry (label) from a cell content with the use of an optional string processing

## Example

```
when
  cell corner: cl == 1, rt == 1, blank
  cell c: cl > corner.cr, rt > corner.rb
then
  new entry c
```

# Structural Analysis

The actions recover pairs of two kinds: entry-label and label-label

- **<add label>** associates an entry with a label
- **<set parent>** binds two labels as a parent and its child

## Example

```
when
  cell c1: cl == 1
  cell c2: cl == 1, rt > c1.rt, indent == c1.indent + 2
  no cells: cl == 1, rt > $c1.rt, rt < $c2.rt, indent == $c1.indent
then
  set parent c1.label to c2.label
```

# Interpretation

The actions serve to recover label-category pairs

- **<set category>** associates a label with a category
- **<group>** places two labels to one group that can be considered as an undefined category

## Example

```
when
  label l1: cell.mark == "stub"
  label l2: cell.mark == "stub", cell.rt == l1.cell.rt
then
  group l1 with l2
```

# Illustrative Example

The transformation of arbitrary tables with the same layout features (a and c) to their canonicalized versions (b and d)

a1	a2
b1	1
b2	2
b3	

*a*

DATA	A	B
1	a1	b1
2	a1	b2
4	a2	b4
6	a2	b6

*b*

a1	a2	a3
b1		b3
b2	2	b4

*c*

DATA	A	B
2	a1	b2
3	a2	b3
5	a3	b5
6	a3	b6

*d*

The ruleset for the cell cleansing (a), role analysis (b, c), structural analysis (d, e), and interpretation (f, g)

*a* when cell c: c.text.matches("NA")  
then set text "" to c

*b* when cell c: (c1 % 2) == 0, !blank  
then new entry c

*c* when cell c: (c1 % 2) == 1  
then new label c

when  
entry e  
label l: cell.cr == e.cell.cr  
then add label l to e

when  
entry e  
*e* label l: cell.rt == e.cell.rt, cell.cl == e.cell.cl - 1  
then add label l to e


*f* when label l: cell.rt == 1  
then set category "A" to l

*g* when label l: cell.rt > 1  
then set category "B" to l

This example is reproducible at

<https://codeocean.com/capsule/5326436>

# Architecture



Two options are provided

## Rule Engine option


Executing a ruleset in an appropriate format with a JSR-94 compatible rule engine (e.g. Drools, Jess)

## CRL2J option

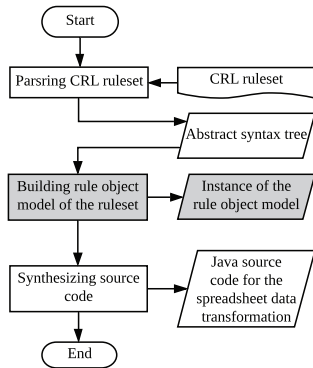
Translating a ruleset expressed in CRL to an executable Java program

# CRL2J Translation


## Workflow for generating a Maven-project of a spreadsheet data transformation program




## Workflow for translating a CRL ruleset to Java source code



## 生成电子表格数据转换程序 Maven 项目的工作流程




## 将 CRL 规则集转换为 Java 源代码的工作流程






# CRL2J Translation


## In the Workflow




## Rule Object Model



## 在工作流程中



## 规则对象模型



# CRL2J Translation

## Example (Source Rule)

```
when
  cell corner: cl == 1, rt == 1, blank
  cell c: cl > corner.cr, rt > corner.rb, ! marked
then
  set mark "@entry" to c
  new entry c
```

## Example (Fragment of the Generated Java Code)

```
...
Iterator<CCell> iterator1 = getTable().getCells();
while (iterator1.hasNext()) {
  corner = iterator1.next();
  if ((corner.getCl() == 1) && (corner.getRt() == 1) && ...
    Iterator<CCell> iterator2 = getTable().getCells();
    while (iterator2.hasNext()) {
  ...
```

## Example (来源规则)

```
when
  cell corner: cl == 1, rt == 1, blank
  cell c: cl > corner.cr, rt > corner.rb, ! marked
then
  set mark "@entry" to c
  new entry c
```

## Example (生成的 Java 代码片段)

```
...
Iterator<CCell> iterator1 = getTable().getCells();
while (iterator1.hasNext()) {
  corner = iterator1.next();
  if ((corner.getCl() == 1) && (corner.getRt() == 1) && ...
    Iterator<CCell> iterator2 = getTable().getCells();
    while (iterator2.hasNext()) {
  ...
```

# Performance Evaluation

The results of the transformation of 200 tables of Troy200 dataset

Metrics	Role analysis		Structural analysis	
	Type of instances			
	entries	labels	entry-label pairs	label-label pairs
Recall	0.9813 $\frac{16602}{16918}$	0.9965 $\frac{4842}{4859}$	0.9773 $\frac{34270}{35066}$	0.9389 $\frac{1951}{2078}$
Precision	0.9996 $\frac{16602}{16609}$	0.9364 $\frac{4842}{5171}$	0.9965 $\frac{34270}{34389}$	0.9784 $\frac{1951}{1994}$
F-score	0.9904	0.9655	0.9868	0.9582

## Metrics

$$\text{recall} = \frac{|R \cap S|}{|S|} \quad \text{precision} = \frac{|R \cap S|}{|R|}$$

$S$  is a set of instances in a source table,  $R$  is a set of instances in its canonical form

All data and steps to reproduce the results are available at <http://dx.doi.org/10.17632/ydcr7mcrtpt.5>

## Troy200 数据集 200 个表格的转换结果

衡量标准	角色分析		结构分析	
	实例类型			
	参赛	标签	条目标签对	标签-标签对
回顾	0.9813 $\frac{16602}{16918}$	0.9965 $\frac{4842}{4859}$	0.9773 $\frac{34270}{35066}$	0.9389 $\frac{1951}{2078}$
精确度	0.9996 $\frac{16602}{16609}$	0.9364 $\frac{4842}{5171}$	0.9965 $\frac{34270}{34389}$	0.9784 $\frac{1951}{1994}$
<i>F</i> -总谱	0.9904	0.9655	0.9868	0.9582

## Metrics

$$\text{回顾} = \frac{|R \cap S|}{|S|} \quad \text{精确度} = \frac{|R \cap S|}{|R|}$$

$S$  是源表中的一组实例,  $R$  是一组典型形式的实例

所有数据和重现结果的步骤可从以下网址获取 <http://dx.doi.org/10.17632/ydcr7mcrtpt.5>

# Performance Evaluation

The comparison of the running time by using TabbyXL with three different options for transforming 200 tables of Troy200 dataset

Running time of	CRL2J	Drools	Jess
Ruleset preparation ( $t_1$ )	2108 <sup>*</sup> ms	1711 <sup>†</sup> ms	432 <sup>†</sup> ms
Ruleset execution ( $t_2$ )	367 <sup>**</sup> ms	1974 <sup>‡</sup> ms	4149 <sup>‡</sup> ms

<sup>\*</sup>  $t_1$  — a time of parsing and compiling the original ruleset into a Java program

<sup>\*\*</sup>  $t_2$  — a time of executing the generated Java program

<sup>†</sup>  $t_1$  — a time of parsing the original ruleset and adding the result into a rule engine session

<sup>‡</sup>  $t_2$  — a time of asserting facts into the working memory and matching rules against the facts

For testing, we used 3.2 GHz 4-core CPU

使用 TabbyXL 对 Troy200 数据集的 200 张表格进行转换时，三种不同选项的运行时间比较

运行时间	CRL2J	Drools	Jess
规则集准备 ( $t_1$ )	2108 <sup>*</sup> ms	1711 <sup>†</sup> ms	432 <sup>†</sup> ms
规则集执行 ( $t_2$ )	367 <sup>**</sup> ms	1974 <sup>‡</sup> ms	4149 <sup>‡</sup> ms

<sup>\*</sup>  $t_1$  — 解析原始规则集并将其编译成 Java 程序的时间

<sup>\*\*</sup>  $t_2$  — 执行生成的 Java 程序的时间

<sup>†</sup>  $t_1$  — 解析原始规则集并将结果添加到规则引擎会话的时间

<sup>‡</sup>  $t_2$  — 在工作记忆中断言事实并将规则与事实相匹配的时间

在测试中，我们使用了主频为 3.2 GHz 的 4 核 CPU



# Comparison with Others

## Role Analysis

- ❑ Contest task: The segmentation of a table into typical functional cell regions
- ❑ Testing dataset: Troy200
- ❑ Contestant: MIPS (TANGO)
- ❑ Accuracy: MIPS (TANGO) — 0.9899 vs. TabbyXL — 0.9950

## Structural Analysis

- ❑ Contest task: The extraction of header hierarchies from tables
- ❑ Testing dataset: A random subset of SAUS<sup>a</sup>
- ❑ Contestant: Senbazuru
- ❑ *F*-score: Senbazuru — 0.8860 vs. TabbyXL — 0.8657

---

<sup>a</sup><http://dbgroupp.eecs.umich.edu/project/sheets/datasets.html>

## 角色分析

- ❑ 竞赛任务: 将表格划分为典型的功能单元区域
- ❑ 测试数据集: Troy200
- ❑ 参赛者: MIPS (TANGO)
- ❑ 准确性: MIPS (TANGO) — 0.9899 vs. TabbyXL — 0.9950

## Structural Analysis

- ❑ 竞赛任务: 从表格中提取表头层次结构
- ❑ 测试数据集: 的一个随机子集 SAUS<sup>a</sup>
- ❑ 参赛者: Senbazuru
- ❑  $F$ -总谱: Senbazuru — 0.8860 vs. TabbyXL — 0.8657

---

<sup>a</sup><http://dbgroup.eecs.umich.edu/project/sheets/datasets.html>

# Application Experience


Populating a web-based statistical atlas of the Irkutsk region —  
(b) via extracting data from government statistical reports — (a)

Corner cell      Head part

	h1	h2				h3	
		h4		h5			
		h6	h7	h8	h9	h10	h11
s1							
..s2	d1	d2	d3	d4	d5	d6	d7
...s3	d8	d9	d10	d11	d12	d13	d14
....s4	d15	d16	d17	d18	d19	d20	d21
...s5	d22	d23	d24	d25	d26	d27	d28
....s6	d29	d30	d31	d32	d33	d34	d35
..s7	d36	d37	d38	d39	d40	d41	d42
...s8	d43	d44	d45	d46	d47	d48	d49
s9	d50	d51	d52	d53	d54	d55	d56

Stub part      Body part      *a*

DATA	HEAD	STUB
d1	h1	s1 s2
d2	h2 h4 h6	s1 s2
d3	h2 h4 h7	s1 s2
d4	h2 h5 h8	s1 s2
d5	h2 h5 h9	s1 s2
d6	h3 h10	s1 s2
d7	h3 h11	s1 s2
d8	h1	s1 s2 s3
d9	h2 h4 h6	s1 s2 s3
d10	h2 h4 h7	s1 s2 s3
d11	h2 h5 h8	s1 s2 s3
d12	h2 h5 h9	s1 s2 s3
d13	h3 h10	s1 s2 s3
d14	h3 h11	s1 s2 s3
...	...	...
d56	h3 h11	s9



*b*

The more detail can be found at <https://github.com/tabbydoc/tabbyxl/wiki/statistical-atlas>


## 绘制伊尔库茨克州网络统计地图集 — (b) 通过从政府统计报告中提取数据 — (a)

Corner cell      Head part

	h1	h2				h3	
		h4		h5			
		h6	h7	h8	h9	h10	h11
s1							
..s2	d1	d2	d3	d4	d5	d6	d7
....s3	d8	d9	d10	d11	d12	d13	d14
....s4	d15	d16	d17	d18	d19	d20	d21
....s5	d22	d23	d24	d25	d26	d27	d28
....s6	d29	d30	d31	d32	d33	d34	d35
..s7	d36	d37	d38	d39	d40	d41	d42
....s8	d43	d44	d45	d46	d47	d48	d49
s9	d50	d51	d52	d53	d54	d55	d56

Stub part      Body part      *a*


DATA	HEAD	STUB
d1	h1	s1 s2
d2	h2 h4 h6	s1 s2
d3	h2 h4 h7	s1 s2
d4	h2 h5 h8	s1 s2
d5	h2 h5 h9	s1 s2
d6	h3 h10	s1 s2
d7	h3 h11	s1 s2
d8	h1	s1 s2 s3
d9	h2 h4 h6	s1 s2 s3
d10	h2 h4 h7	s1 s2 s3
d11	h2 h5 h8	s1 s2 s3
d12	h2 h5 h9	s1 s2 s3
d13	h3 h10	s1 s2 s3
d14	h3 h11	s1 s2 s3
...	...	...
d56	h3 h11	s9



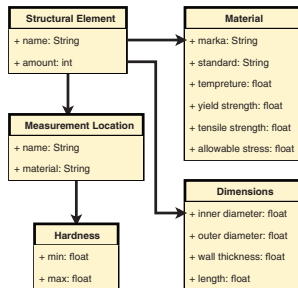
更多详情请访问 <https://github.com/tabbydoc/tabbyxl/wiki/statistical-atlas>

# Application Experience

Generating conceptual models — (b) from arbitrary tables presented in industrial safety inspection reports — (a)




DATA	HEAD	S
d1	h1	s1
d1	h1	s2
d2	h1	s3
d3	h1	s4
d3	h1	s5
d4	h2   h3	s1
d4	h2   h3	s2
d4	h2   h3	s3
d5	h2   h3	s4
d6	h2   h3	s5
...	...	...
d17	h8   h9	s5




The more detail can be found at <https://github.com/tabbydoc/tabbyxl/wiki/industrial-safety-inspection>

## 生成概念模型 — (b) 来自工业安全检查报告中的任意表格 — (a)



DATA	HEAD	S
d1	h1	s1
d1	h1	s2
d2	h1	s3
d3	h1	s4
d3	h1	s5
d4	h2   h3	s1
d4	h2   h3	s2
d4	h2   h3	s3
d5	h2   h3	s4
d6	h2   h3	s5
...	...	...
d17	h8   h9	s5



更多详情请访问 <https://github.com/tabbydoc/tabbyxl/wiki/industrial-safety-inspection>

# Conclusions & Further Work

- ❑ Impact on software development for spreadsheet data management
  - ▶ Table object model associating functional roles with data items
  - ▶ Table analysis and interpretation driven by user-defined rules
  - ▶ Formulated actions to recover missing semantics of arbitrary tables
  - ▶ Translation of rules to executable spreadsheet transformation programs
- ❑ Limitations
  - ▶ The inaccurate cell structure prevents the table analysis
  - ▶ The very limited interpretation (without external vocabularies)
- ❑ Further work
  - ▶ Rearrangement of cell structure by using visual (human-readable) cells
  - ▶ Detecting derived data by spreadsheet formulas
  - ▶ Enriching the table analysis by named entity recognition
  - ▶ Linking extracted data items with LOD cloud

- 对电子表格数据管理软件开发的影响
  - ▶ 将功能角色与数据项关联起来的表对象模型
  - ▶ 根据用户定义的规则进行表格分析和解释
  - ▶ 为恢复任意表的缺失语义而制定的行动
  - ▶ 将规则转化为可执行的电子表格转换程序
- 局限性
  - ▶ 不准确的单元格结构妨碍了表格分析
  - ▶ 非常有限的解释（没有外部词汇表）
- 进一步的工作
  - ▶ 利用可视（人类可读）细胞重新排列细胞结构
  - ▶ 通过电子表格公式检测派生数据
  - ▶ 通过命名实体识别丰富表格分析
  - ▶ 将提取的数据项与 LOD 云连接起来



# Thanks!

Read more about the project at  
<http://td.icc.ru>

The project source code is available at  
<https://github.com/tabbydoc/tabbyxl>

## But it is not all ...

# 谢谢!

有关该项目的更多信息，请访问

<http://td.icc.ru>

项目源代码见

<https://github.com/tabbydoc/tabbyxl>

## 但这并不是全部 ...

# Domain Knowledge Graphs Induction from Tables

Tables are the most available sources of information. They are valuable data sources for Knowledge Bases (KB)

**Knowledge Base Construction** Populating with document and structured table extracted data

**Knowledge Base Population** Populating with recognized new facts on entities from big text corpses

**Knowledge base Augmentation** Populating with relations with table data.

1. (Ré, 2014) Ré C., et al. Feature engineering for knowledge base construction. IEEE Data Eng. Bull., 37, 26–40, (2014).
2. (Balog, 2018) Balog K. Populating knowledge bases. Entity-Oriented Search. INRE, 39, 189–222, (2018).
3. (Zhang & Balog, 2020) Zhang S. & Balog K. Web table extraction, retrieval, and augmentation: A survey. ACM Trans. Intell. Syst. Technol., 11, (2020).

表格是最常用的信息来源。它们是知识库（KB）的重要数据源

知识库建设 填充文件和结构化表格提取的数据

知识库人口 从大文本尸体中填充关于实体的公认新事实

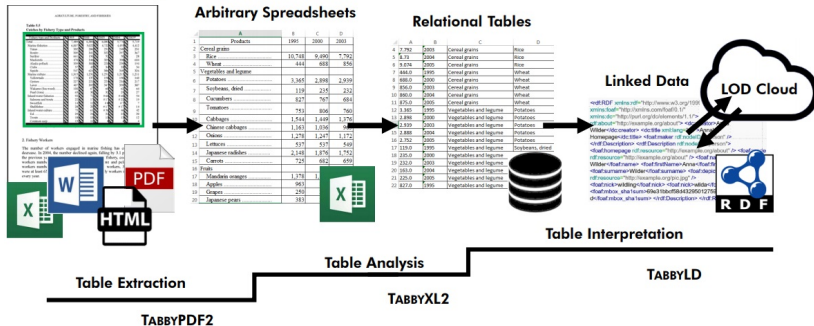
知识库扩充 用表格数据填充关系

1. (Ré, 2014) Ré C., et al. Feature engineering for knowledge base construction. IEEE Data Eng. Bull., 37, 26–40, (2014).
2. (Balog, 2018) Balog K. Populating knowledge bases. Entity-Oriented Search. INRE, 39, 189–222, (2018).
3. (Zhang & Balog, 2020) Zhang S. & Balog K. Web table extraction, retrieval, and augmentation: A survey. ACM Trans. Intell. Syst. Technol., 11, (2020).



## 自动表格解释有三个主要阶段 (Shigarov, 2017)

Weakly- and Semi-Structured Documents



- (Shigarov, 2017) Shigarov A., Mikhailov A. Rule-based spreadsheet data transformation from arbitrary to relational tables. Information Systems, 71, 123-136 (2017).

# Semantic Table Interpretation

Semantic interpretation (Annotation) of tables (Semantic Table Interpretation, STI) is a recognition of mutual and external relations between elements of table content. Externals relate to an enterprise KG and/or a global KG (e.g. DBPedia.org).

- ❑ Cell-Entity Annotation (CEA)
- ❑ Column-Type Annotation (CTA)
- ❑ Column Property Annotation (CPA)
- ❑ Topic Annotation








The diagram shows a table of tennis players with various semantic annotations. A blue box labeled 'Topic annotation dbr:ATP\_rankings' highlights the first four rows. A red box labeled 'CEA dbr:Daniil\_Medvedev' highlights the cell containing 'Daniil Medvedev'. A green box labeled 'dbo:rankingsSingles CPA' highlights the first five rows. A red box labeled 'dbo:Country CTA' highlights the 'Country' column. The table data is as follows:

1		Carlos Alcaraz	Spain	7,420	▲ 1
2		Novak Djokovic	Serbia	7,160	▼ 1
3		Stefanos Tsitsipas	Greece	5,770	—
4		Casper Ruud	Norway	5,560	—
5		Daniil Medvedev	Russia	4,330	▲ 1
6		Félix Auger-Aliassime	Canada	3,415	▲ 4
7		Andrey Rublev	Russia	3,390	—

# Semantic Table Interpretation

表格的语义解释（注释）(Semantic Table Interpretation, STI)  
是对表格内容元素之间相互关系和外部关系的一种确认。  
外部关系涉及企业 KG  
和/或全局 KG (例如 DBPedia.org)。

- ❑ 细胞实体注释 (CEA)
- ❑ 列式注释 (CTA)
- ❑ 列属性注释 (CPA)
- ❑ 主题注释

Topic annotation dbr:ATP_rankings		1		Carlos Alcaraz	Spain	7,420	▲ 1
		2		Novak Djokovic	Serbia	7,160	▼ 1
		3		Stefanos Tsitsipas	Greece	5,770	—
		4		Casper Ruud	Norway	5,560	—
CEA dbr:Daniil_Medvedev		5		Daniil Medvedev	Russia	4,330	▲ 1
		6		Félix Auger-Aliassime	Canada	3,415	▲ 4
		7		Andrey Rublev	Russia	3,390	—

dbo:rankingsSingles  
CPA

dbo:Country  
CTA



# Cell-Entity Annotation

CEA comprises the sequential steps as follows:

1. Select a candidate entity set from DBpedia.org for each value of a cell via SPARQL endpoint and DBpedia lookup.
2. Disambiguation

A SPARQL-query matching words of a phrase.

```
SELECT DISTINCT (str(?subject) as ?subject)
WHERE {
    ?subject a ?type .
    ?subject rdfs:label ?label .
    ?label <bif:contains> ".*%value1*." AND ".*%value2*." ... .
    FILTER NOT EXISTS { ?subject dbo:wikiPageRedirects ?r2 } .
    FILTER (!strstarts(str(?subject), "http://dbpedia.org/resource/"))
    FILTER (!strstarts(str(?subject), "http://dbpedia.org/property/"))
    FILTER (!strstarts(str(?subject), "http://dbpedia.org/ontology/"))
    FILTER (strstarts(str(?type), "http://dbpedia.org/ontology/")) .
    FILTER (lang(?label) = "en")
}
ORDER BY ASC(strlen(?label))
LIMIT 100
```

# 细胞实体注释

CEA 包括以下三个连续步骤：

1. 通过 SPARQL 端点和 DBPedia 查找，为单元格的每个值从 DBPedia.org 中选择一个候选实体集。
2. 消歧义

匹配短语单词的 SPARQL 查询。

```
SELECT DISTINCT (str(?subject) as ?subject)
WHERE {
    ?subject a ?type .
    ?subject rdfs:label ?label .
    ?label <bif:contains> ".*%value1*." AND ".*%value2*." ... .
    FILTER NOT EXISTS { ?subject dbo:wikiPageRedirects ?r2 } .
    FILTER (!strstarts(str(?subject), "http://dbpedia.org/resource/C
    FILTER (!strstarts(str(?subject), "http://dbpedia.org/property/"
    FILTER (!strstarts(str(?subject), "http://dbpedia.org/ontology/"
    FILTER (strstarts(str(?type), "http://dbpedia.org/ontology/")) .
    FILTER (lang(?label) = "en")
}
ORDER BY ASC(strlen(?label))
LIMIT 100
```

# Evaluation on Test Table Sets

A well-known precision measurement (accuracy) is used for assessment

$$\text{Accuracy} = \frac{CC}{NC},$$

where  $CC$  is the number of the correctly related columns to a categorical entity, and  $CN$  is the total number of columns.

Recognition stage	T2Dv2	Tough_Tables	Git-Tables
Stage 2, Atomic column classification	0.994	0.956	0.938
Stage 3, Column entity identification	0.924	–	–

Comparison with analogs

	TAIPAN	Table-Miner+	T2Dv2	Mantis-Table
Column entity identification	0.540	0.871	0.924	0.979

# Evaluation on Test Table Sets

采用众所周知的精确测量（精度）进行评估

$$\text{准确性} = \frac{CC}{NC},$$

其中， $CC$  是与分类实体正确相关的列数， $CN$  是列的总数。

认可阶段	T2Dv2	Tough_Tables	Git-Tables
第 2 阶段，原子柱分类	0.994	0.956	0.938
第 3 阶段，列实体识别	0.924	–	–


与类似物的比较

	TAIPAN	Table-Miner+	T2Dv2	Mantis-Table
列实体标识	0.540	0.871	0.924	0.979

# Knowledge Representation and Reasoning: the PCF-Calculus


The main properties of the language of positively constructed formulas (PCF) and its calculi:

- ❑ PCFs have a large-block structure (tree-like) and consist of only positive quantifiers  $\exists$  and  $\forall$
- ❑ the PCF-based calculus have a unique inference rule
- ❑ the proof in the PCF-calculus is organized as a question-answering procedure
- ❑ PCF-calculus is both machine-oriented and human-oriented; it is compatible with heuristics
- ❑ the semantic of the PCF-calculus can be changed without modifying axioms and the inference rule





正构造公式（PCF）语言及其计算器的主要特性：

- ❑ PCF 具有大块结构（树状），仅由正量词 $\exists$ 和 $\forall$ 组成。
- ❑ 基于 PCF 的微积分有一个唯一的推理规则





- ❑ PCF 微积分中的证明是以问题解答过程的形式组织的
- ❑ PCF 微积分既面向机器，也面向人类；它与启发式方法兼容
- ❑ 可以在不修改公理和推理规则的情况下改变 PCF 微积分的语义

# PCF-Based Method for Problem Solving



- ❑ The goal of the team of robot is to transport blocks to the target area
- ❑ Each block can be dragged by two or more robots
- ❑ The current state of the World and the goal of the group are formalized in PCF
- ❑ The PCF-based prover and a selection mechanism produce the optimal joint plan of actions for the team
- ❑ The current plan can be easily modified whenever the state of the World is changed

# 基于 PCF 的问题解决方法



- ❑ 机器人团队的目标是将积木运送到目标区域
- ❑ 每个积木可由两个或多个机器人拖动
- ❑ 世界的当前状态和小组的目标在 PCF 中形式化为
- ❑ 基于 PCF 的求证器和选择机制为团队生成最优的联合行动计划
- ❑ 只要”世界”的状态发生变化, 就可以轻松修改当前计划



# A Master Degree Program. Semantic Technologies and Multiagent Systems

It is a joint effort of Saint-Petersburg Electrotechnical University (LETI), Irkutsk State University, and ISDCT SB RAS. Main subjects.

- ❑ Computation Geometry, Digital Signal Processing, Internet of Things,
- ❑ Semantic web, Semantic web Information System Development,
- ❑ AI Basics, Knowledge representation, Object-oriented Logic Programming,
- ❑ Answer Set Programming (SAT), Natural Language Processing,
- ❑ Machine Learning, Neural Networks, Deep Learning,
- ❑ Multiagent Systems, Optimization with Multiagent Systems.

Started at 2022-09-01.

<https://etu.ru/sveden/education/programs/semanticheskie-tehnologii-i-mnogoagentnye-sistemy-01.04.02.html>

# A Master Degree Program. 语义技术与多代理系统

该课程由圣彼得堡电工技术大学（LETI）、伊尔库茨克国立大学（Irkutsk State University）和俄罗斯科学院空间技术研究所（ISDCT SB RAS）联合开设。

主要课题。

- 计算几何、数字信号处理、物联网、
- 语义网、语义网信息系统开发、
- 人工智能基础、知识表示、面向对象逻辑编程、
- 答案集编程 (SAT)、自然语言处理、
- 机器学习、神经网络、深度学习、
- 多代理系统，多代理系统优化。

始于 2022-09-01。

<https://etu.ru/sveden/education/programs/semanticheskie-tehnologii-i-mnogoagentnye-sistemy-01.04.02.html>

# Conclusion (the final one)

- ❑ Classic knowledge-based systems are powerful AI tools for solving wide class of recognition problems and synthesis of various kind: source code, data objects, control
- ❑ Contemporary means combine classic and new approaches
- ❑ Less dependent on computational resources (as compared to machine learning)
- ❑ Allow justification of the produced solutions
- ❑ Cover a larger set of tasks
- ❑ Natural for math science, and require higher level of AI education

# 结论（最后）

- ❑ 经典的基于知识的系统是强大的人工智能工具，  
可用于解决广泛的识别问题和各种综合问题：  
源代码、数据对象、控制、数据处理、数据分析、数据挖掘。
- ❑ 当代手段结合了经典方法和新方法
- ❑ 较少依赖计算资源（与机器学习相比）
- ❑ 允许对所产生的解决方案进行论证
- ❑ 涵盖更多任务
- ❑ 自然适用于数学科学，需要更高水平的人工智能教育

Thank You!  
谢谢大家!

